Statystyczna Analiza Danych

Zastosowanie technik PCA oraz MDS

1 Wprowadzenie

Celem niniejszego projektu jest analiza statystyczna osiągnięć zawodników ligi NBA występujących na pozycji środkowego (Center) w sezonie 2023. W dobie rosnącej roli analityki sportowej, ocena przydatności i efektywności graczy wymaga uwzględnienia wielu zróżnicowanych wskaźników jednocześnie – od podstawowych zdobyczy punktowych i zbiórek, po skuteczność rzutów i wskaźniki wpływu na grę zespołu.

Główną metodą badawczą zastosowaną w pracy jest Analiza Głównych Składowych (PCA). Pozwoli ona na redukcję wymiarowości zbioru danych i wyodrębnienie kluczowych czynników (składowych), które wyjaśniają największą część zmienności w statystykach zawodników. Dzięki PCA możliwe będzie wskazanie, które cechy najbardziej różnicują środkowych oraz czy istnieją ukryte wzorce (np. podział na graczy defensywnych i ofensywnych), które nie są widoczne przy analizie pojedynczych zmiennych.

Jako uzupełnienie analizy PCA, w dalszej części raportu zostanie przeprowadzone Skalowanie Wielowymiarowe (MDS). Metoda ta posłuży do wizualizacji relacji pomiędzy zawodnikami poprzez odwzorowanie ich podobieństwa w przestrzeni wielowymiarowej. Pozwoli to na intuicyjną identyfikację graczy o zbliżonym profilu statystycznym oraz ewentualnych obserwacji odstających.

1.1 Biblioteki

```r
library(dplyr)
library(tidyr)
library(psych)
library(knitr)
library(kableExtra)
library(ggplot2)
library(zoo)
library(lubridate)
library(gridExtra)
library(MuMIn)
library(tseries)
library(readxl)
library(corrplot)
library(base)
library(stats)
library(factoextra)
library(MASS)
library(rgl)
```

2 Wczytanie i przygotowanie danych

2.0.1 Struktura danych

Tabela 1: *Struktura i opis zmiennych (nazwy pobrane automatycznie)*

Nazwa zmiennej	Typ danych	Opis zmiennej
PName	*character*	Imię i nazwisko zawodnika
GP	*integer*	Liczba rozegranych meczów (Games Played)
W	*integer*	Liczba zwycięstw (Wins)
L	*integer*	Liczba porażek (Losses)
Min	*numeric*	Średnia liczba minut na mecz
PTS	*integer*	Liczba zdobytych punktów
FG.	*numeric*	Skuteczność rzutów z gry (%)
X3P.	*numeric*	Skuteczność rzutów za 3 punkty (%)
FT.	*numeric*	Skuteczność rzutów wolnych (%)
OREB	*integer*	Zbiórki w ataku (Offensive Rebounds)
DREB	*integer*	Zbiórki w obronie (Defensive Rebounds)
BLK	*integer*	Bloki (Blocks)
X...	*integer*	Wskaźnik Plus/Minus (wpływ zawodnika na wynik zespołu)

Tabela 2: *Podgląd struktury danych (pierwsze 5 obserwacji)*

	PName	GP	W	L	Min	PTS	FG.	X3P.	FT.	OREB	DREB	BLK	X...
Joel.Embiid	Joel Embiid	66	43	23	2284,1	2183	54,8	33,0	85,7	113	557	112	424
Nikola.Jokic	Nikola Jokic	69	48	21	2323,0	1690	63,2	38,3	82,2	167	650	47	640
Bam.Adebayo	Bam Adebayo	75	40	35	2598,0	1529	54,0	8,3	80,6	184	504	61	117
Kristaps.Porzingis	Kristaps Porzingis	65	27	38	2119,5	1505	49,8	38,5	85,1	114	432	100	80
Nikola.Vucevic	Nikola Vucevic	82	40	42	2746,4	1447	52,0	34,9	83,5	159	744	57	-20

2.0.2 Statystyki opisowe

Tabela 3: *Podstawowe statystyki opisowe zmiennych*

Zmienna	Minimum	Mediana	Maksimum	Skośność	Kurtoza	Średnia	Odchylenie
PName*	1,0	39,50	78,0	0,00	-1,25	39,50	22,66
GP	1,0	51,00	82,0	-0,41	-1,09	47,46	23,92
W	0,0	24,00	57,0	0,07	-0,93	23,26	13,88
L	1,0	24,50	57,0	0,10	-0,71	24,21	13,45
Min	19,6	838,55	2746,4	0,41	-1,16	1017,23	790,95
PTS	6,0	342,00	2183,0	1,26	1,35	482,76	464,77
FG.	25,0	56,80	81,9	-0,54	0,93	57,40	10,67
X3P.	0,0	25,75	100,0	0,86	1,02	23,94	22,76
FT.	0,0	70,00	100,0	-1,37	3,09	67,50	18,37
OREB	1,0	74,00	267,0	0,61	-0,88	96,15	78,77
DREB	1,0	166,50	744,0	0,71	-0,51	218,72	187,92
BLK	0,0	30,00	193,0	1,51	2,32	43,59	43,32
X...	-327,0	-7,00	640,0	1,14	3,05	9,55	156,00

Analiza statystyk opisowych ujawnia bardzo duże zróżnicowanie w badanej grupie środkowych. Wskazuje na to wysokie odchylenie standardowe przy większości zmiennych liczbowych (np. PTS, Min, DREB).

Warto zwrócić uwagę na ogromną przepaść między wartościami średnimi a maksymalnymi. Przykładowo, średnia liczba punktów (PTS) wynosi ok. 483, podczas gdy najlepszy zawodnik zdobył ich aż 2183. Świadczy to o specyfice ligi NBA: mamy do czynienia z wąską grupą gwiazd (outlierów) o wybitnych osiągach oraz szeroką grupą zadaniowców.

Dodatkowo, dodatnie wartości skośności (dla PTS 1.26, BLK 1.51) sugerują rozkład prawoskośny – większość zawodników osiąga wyniki poniżej średniej, a średnią zawyżają nieliczni liderzy.

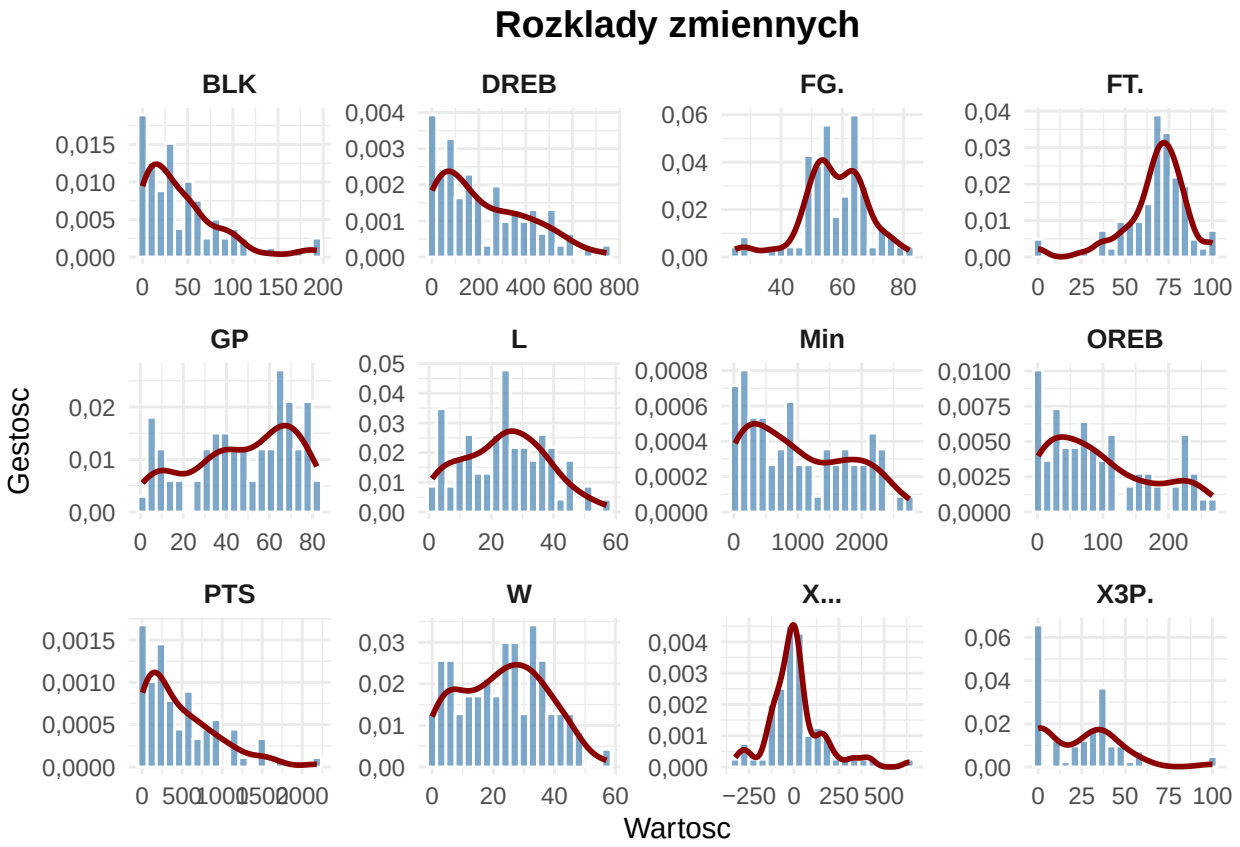

Analiza wizualna histogramów potwierdza wnioski płynące z tabeli statystyk:

Rozkłady prawoskośne (niesymetryczne): Zmienne takie jak bloki (BLK), punkty (PTS) czy wskaźnik +/- (X…) wykazują silną asymetrię prawostronną. Na wykresach widać wysokie słupki po lewej stronie (dużo graczy z niskimi wynikami) i długi "ogon" po prawej. Ten ogon to są właśnie nieliczne gwiazdy w lidze.

Rozkłady lewoskośne (niesymetryczne): Zmienne takie jak skuteczność rzutów wolnych (FT.) czy rozegrane mecze wykazują asymetrię lewostronną. Wynika to z faktu, że rzuty wolne to teoretycznie najłatwiejsze szanse dla zawodników na zdobycie punktów. Od każdego zawodnika bez względu na jego pozycję, wymaga się aby jego skuteczność była jak najwyższa. Jeśli chodzi o rozegrane mecze, w składach drużyn NBA jest najmniej centrów. Z tego powodu częściej występują w meczach.

Rozkłady zbliżone do normalnego: Zmienne określające skuteczność, takie jak FG. (skuteczność z gry), mają rozkład bardziej przypominający kształt dzwonu. Oznacza to, że większość środkowych rzuca na podobnym poziomie skuteczności (ok. 57%), a skrajnie nieskuteczni lub wybitnie skuteczni gracze są rzadkością.

Wnioski dla modelowania: Tak silna skośność zmiennych liczbowych jest ważnym sygnałem przed zastosowaniem PCA, ponieważ metoda ta jest wrażliwa na wartości odstające. Potwierdza to konieczność standaryzacji danych przed dalszą analizą.

Tabela 4: *Analiza wartości odstających: Porównanie profili liderów z tłem ligi*

Zawodnik	PTS	Zbiórki	Bloki	3P%	FT%	+/-	Min
Joel Embiid	2183,0	670,0	112,0	33,0	85,7	424,0	2284,1
Nikola Jokic	1690,0	817,0	47,0	38,3	82,2	640,0	2323,0
Bam Adebayo	1529,0	688,0	61,0	8,3	80,6	117,0	2598,0
Brook Lopez	1239,0	520,0	193,0	37,4	78,4	398,0	2372,5
Steven Adams	361,0	485,0	46,0	0,0	36,4	243,0	1133,3
Średnia Ligowa (Reszta)	419,9	292,9	40,3	24,0	67,1	-14,8	940,2

Powyższa tabela pokazuje kilku zawodników, będących reprezentantami wartości skrajnych dla różnych zmiennych:

1. Joel Embiid - PTS & FT%: Embiid jest fenomenem ataku. Zdobywa 5-krotnie więcej punktów (2183) niż ligowa średnia. Co kluczowe, łączy to ze skutecznością rzutów wolnych na poziomie 85.7%.

2. Nikola Jokić - Plus/Minus (+/-): Jokić dominuje w statystyce wpływu na zespół (+640).

3. Brook Lopez - Bloki & 3P%: Lopez to unikalny przypadek łączący elitarną ochronę obręczy (193 bloki) z rzutami z dystansu (37.4%).

4. Bam Adebayo - Minuty: Adebayo spędza na parkiecie blisko 2600 minut (przy średniej ligowej 937), co czyni go niezastąpionym elementem defensywy swojego zespołu.

5. Steven Adams - FT% (Rzuty Wolne): Adams reprezentuje “lewy ogon” rozkładu skuteczności. Jego skuteczność z linii rzutów wolnych wynosi zaledwie 36.4% (przy średniej ligowej 67% i wyniku Embiida 85%).

2.0.3 Wyznaczanie macierzy korelacji

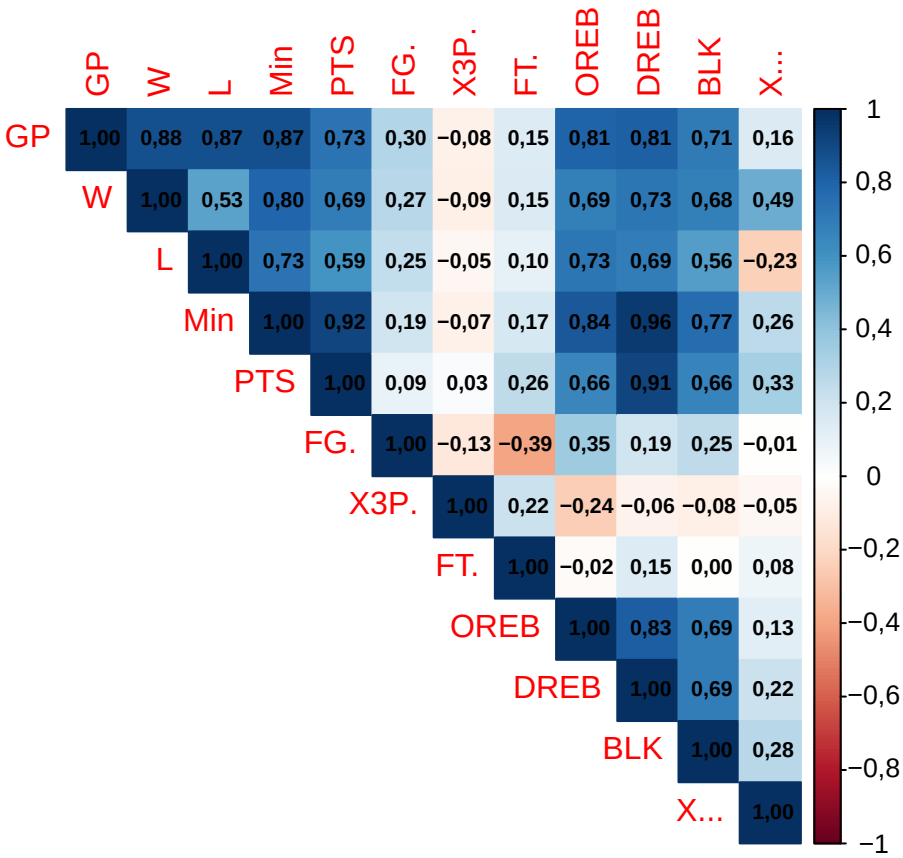

Analiza macierzy korelacji dostarcza kluczowych informacji na temat powiązań między zmiennymi, co stanowi fundament pod redukcję wymiarowości metodą PCA:

- Obserwujemy bardzo silne, dodatnie korelacje między czasem gry (Min), punktami (PTS), zbiórkami (DREB, OREB) oraz blokami (BLK). Współczynniki korelacji w tym klastrze często przekraczają poziom $r > 0.7$ (np. PTS i Min $r \approx 0.9$, PTS i FT% $r \approx 0.76$). Jest to sygnał występowania współliniowości. Oznacza to, że te zmienne niosą powieloną informację – lepsi zawodnicy grają dłużej i zdobywają więcej punktów/zbiórek we wszystkich kategoriach. PCA pozwoli skompresować te wszystkie zmienne do jednej głównej składowej (prawdopodobnie PC1), interpretowanej jako “Ogólna jakość/efektywność zawodnika”.
- Umiejętność rzucania za 3 punkty jest u środkowych (Center) cechą specyficzną, niezależną od bycia dobrym zbierającym czy blokującym. Sugeruje to, że ta zmienna będzie silnie rzutować na drugą lub trzecią składową główną (PC2/PC3), różnicując graczy na typowych “podkoszowych” i nowoczesnych “stretch fives”.
- Silna korelacja między zbiórkami w obronie (DREB) a blokami (BLK) ($r \approx 0.7$) potwierdza, że kompetencje defensywne zazwyczaj idą w parze. PCA pozwoli połączyć te cechy w jeden wymiar opisujący potencjał obronny.

3 PCA

3.1 Test Bartletta

Weryfikacja czy zmienne są wystarczająco skorelowane ze sobą, aby przeprowadzić PCA.

Tabela 5: *Wyniki testu sferyczności Bartletta*

Statystyka	Wartość	Stopnie.swobody..df.	p.value
Chi-kwadrat	3387,5	66	< 0.001

Hipoteza zerowa (H_0) tego testu zakłada, że macierz korelacji jest macierzą jednostkową, co oznaczałoby brak istotnych związków między cechami zawodników.Uzyskana wartość prawdopodobieństwa testowego (p-value < 0.001) jest znacznie niższa od przyjętego poziomu istotności $\alpha = 0.05$. Daje to podstawy do odrzucenia hipotezy zerowej.

Wniosek Odrzucenie hipotezy zerowej potwierdza, że pomiędzy analizowanymi statystykami (takimi jak punkty, zbiórki, czas gry) występują istotne statystycznie korelacje. Oznacza to, że dane zawierają ukryte struktury, które można skutecznie wyodrębnić, a zastosowanie Analizy Głównych Składowych (PCA) jest w tym przypadku w pełni uzasadnione merytorycznie i statystycznie.

3.2 Wyznaczanie wartości własnych

Tabela 6: *Wartości własne i procent wyjaśnianej wariancji*

	Wartość własna	% wariancji	% skumulowany
Dim.1	**6,46**	**53,81**	**53,81**
Dim.2	**1,63**	**13,56**	**67,36**
Dim.3	**1,29**	**10,77**	**78,13**
Dim.4	0,90	7,49	85,62
Dim.5	0,57	4,71	90,33
Dim.6	0,40	3,35	93,67
Dim.7	0,34	2,80	96,47
Dim.8	0,21	1,77	98,24
Dim.9	0,15	1,21	99,45
Dim.10	0,04	0,35	99,80
Dim.11	0,02	0,20	100,00
Dim.12	0,00	0,00	100,00

3.3 Wizualizacja wartości własnych

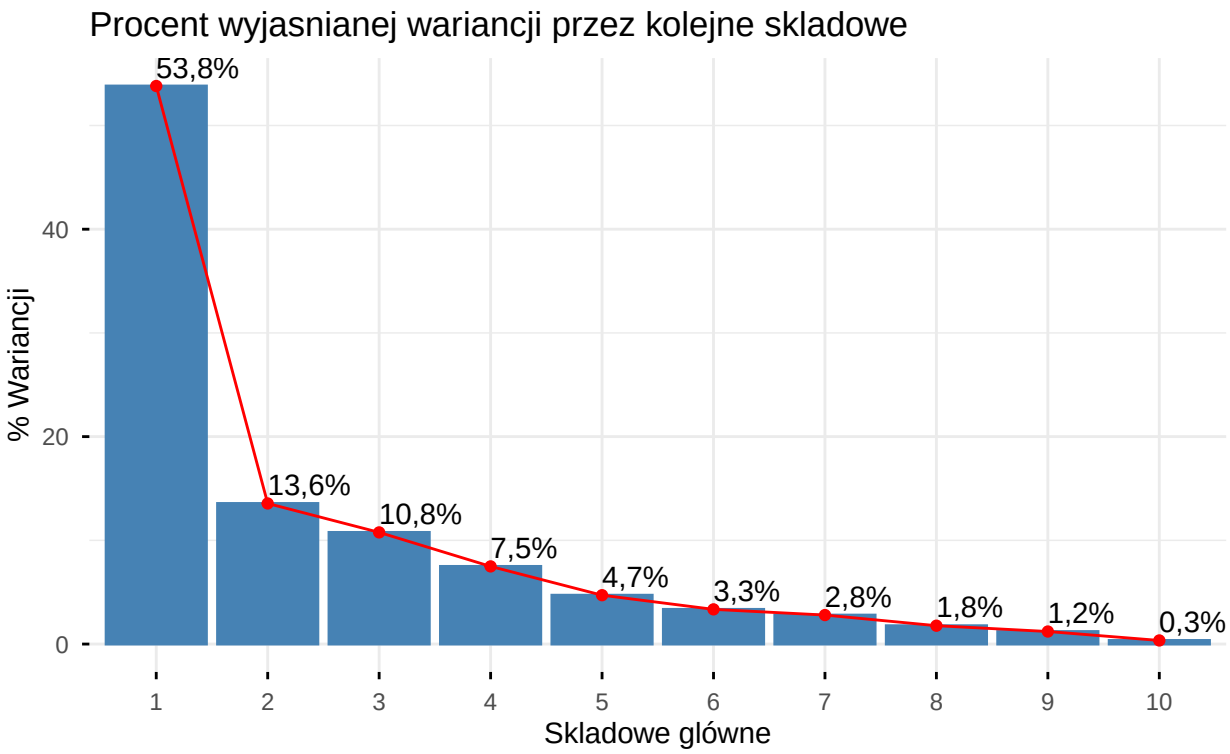

Ze względu na ograniczenia percepcji wykresów trójwymiarowych na płaszczyźnie, interpretacja zostanie przeprowadzona dwuetapowo:

- Analiza głównego układu PC1 vs PC2 (wyjaśniającego większość, bo aż 67% zmienności).
- Analiza uzupełniająca układu PC1 vs PC3, co pozwoli zinterpretować znaczenie trzeciego wymiaru i zidentyfikować zjawiska, których nie widać na pierwszym rzucie.

Tabela 7: *Ładunki czynnikowe (korelacje zmiennych ze składowymi)*

	PC1	PC2	PC3
GP	**-0,370**	-0,028	-0,115
W	**-0,339**	0,063	0,243
L	**-0,308**	-0,115	**-0,456**
Min	**-0,383**	0,073	-0,018
PTS	**-0,343**	0,208	0,031
FG.	-0,117	**-0,550**	0,087
X3P.	0,043	**0,381**	-0,252
FT.	-0,053	**0,623**	-0,194
OREB	**-0,347**	-0,177	-0,049
DREB	**-0,368**	0,064	-0,040
BLK	**-0,320**	-0,048	0,110
X...	-0,107	0,244	**0,771**

3.4 Wizualizacja 2D i 3D w płaszczyźnie

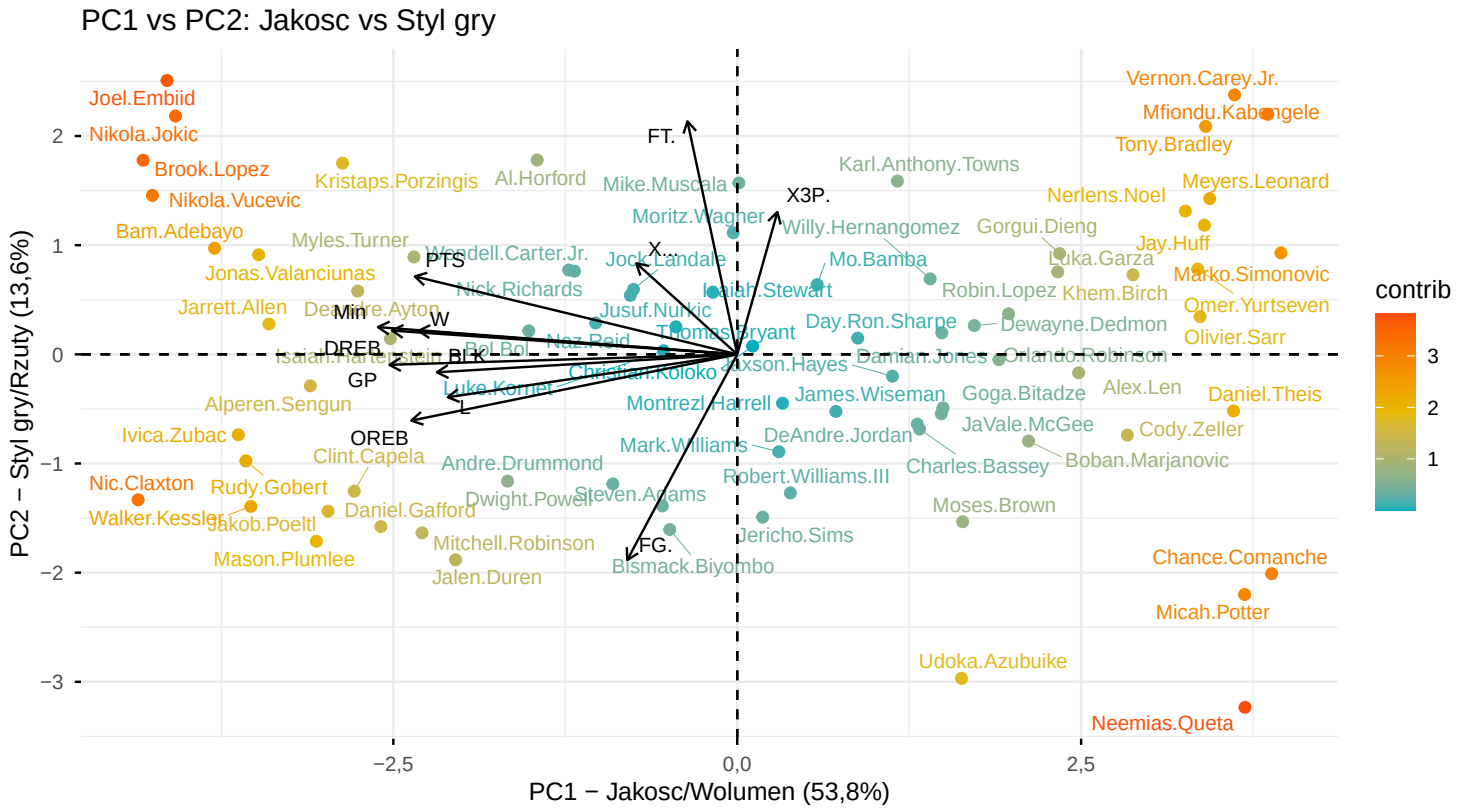

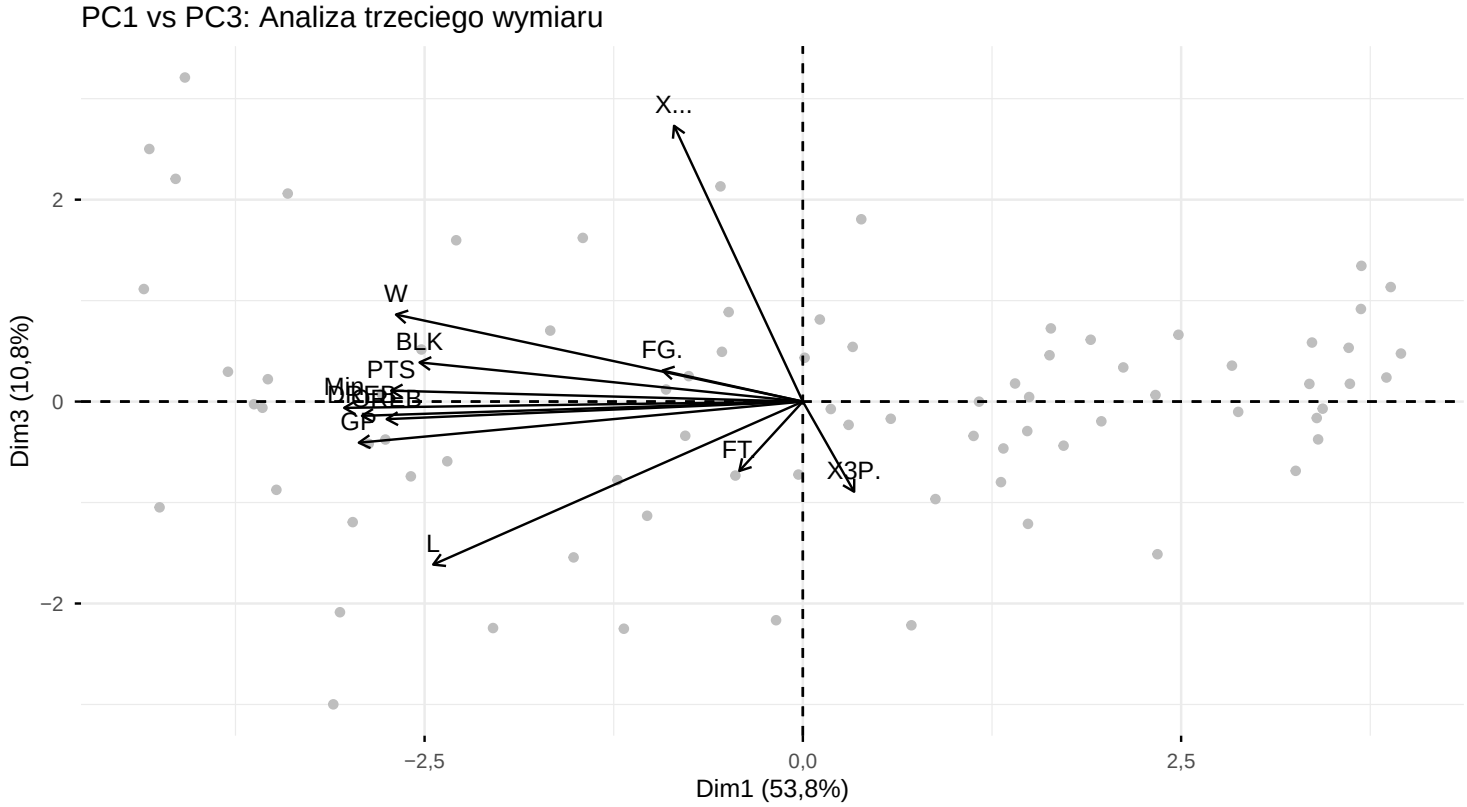

3.5 Wnioski z analizy PCA

Przeprowadzona Analiza Głównych Składowych (PCA) pozwoliła zredukować wielowymiarową przestrzeń 12 statystyk do trzech kluczowych wymiarów (składowych), które łącznie wyjaśniają 78,13% całkowitej zmienności w zbiorze danych. Analiza ładunków czynnikowych oraz wykresów biplot pozwoliła na zidentyfikowanie następujących wzorców charakteryzujących środkowych (Center) w NBA:

1. PC1: Oś “Jakości i Wolumenu Gry” (53,8% wariancji) Pierwsza składowa stanowi najważniejszy wyznacznik klasy zawodnika.

Charakterystyka: Zmienna ta jest silnie ujemnie skorelowana z kluczowymi statystykami ilościowymi: czasem gry (Min, ładunek -0.38), punktami (PTS, -0.34) oraz zbiórkami (DREB, -0.37).

Interpretacja wykresu: Na wykresie Biplot (PC1 vs PC2) obserwujemy, że “najlepsi” zawodnicy znajdują się po lewej stronie (wartości ujemne PC1).

Wnioski: Oś ta segreguje graczy od rezerwowych i zadaniowców (prawa strona wykresu) do supergwiazd ligi (skrajna lewa strona).

2. PC2: Oś “Stylu Gry” – Nowoczesność vs Tradycja (13,6% wariancji) Druga składowa jest niezależna od jakości gracza i opisuje jego profil boiskowy.

Wartości dodatnie (Góra wykresu): Są silnie powiązane ze skutecznością rzutów wolnych (FT., 0.62) oraz rzutami za trzy punkty (X3P., 0.38). Reprezentują one typ “Stretch Five” – środkowych rozciągających grę i grożących rzutem z dystansu.

Wartości ujemne (Dół wykresu): Korelują ze skutecznością z gry (FG., -0.55) i zbiórkami ofensywnymi (OREB). Wskazuje to na tradycyjnych centrów (tzw. Paint Beasts), którzy operują w strefie podkoszowej, zdobywając punkty z wsadów i dobitek.

3. PC3: Oś “Wpływu na Zwycięstwa” (Impact) (10,8% wariancji) Trzecia składowa, choć wyjaśnia najmniej wariancji, wnosi kluczowy kontekst dotyczący efektywności zespołowej.

Charakterystyka: Najsilniejszy ładunek czynnikowy posiada tutaj wskaźnik Plus/Minus (X…, 0.77) oraz liczba zwycięstw (W, 0.24).

Wnioski: PC3 pozwala odróżnić zawodników, którzy robią “puste statystyki” w słabych zespołach, od tych, którzy realnie przekładają się na wygrane drużyny. Wysoka wartość na tej osi oznacza, że obecność danego gracza na parkiecie koreluje z lepszym wynikiem punktowym całego zespołu.

Podsumowanie: Zastosowanie metody PCA ujawniło, że pozycja środkowego w NBA uległa silnej polaryzacji. Podczas gdy pierwsza składowa (PC1) wciąż definiuje hierarchię “gwiazda vs rezerwowy”, to druga składowa (PC2) pokazuje, że istnieją dwie równorzędne drogi do bycia efektywnym: dominacja fizyczna pod koszem lub umiejętności strzeleckie na obwodzie.

3.5.1 Reprezentanci powstałych grup

Aby lepiej zrozumieć, co determinuje pozycję zawodników na wykresie PCA, przyjrzyjmy się czterem charakterystycznym grupom, które definiują granice naszego układu współrzędnych:

1. Lewa Górna Część: To elita nowoczesnej koszykówki. Są to kluczowi zawodnicy swoich drużyn, którzy wyróżniają się unikalną umiejętnością: mimo wysokiego wzrostu potrafią skutecznie rzucać za 3 punkty. Dzięki temu są groźni na całym boisku – nie tylko pod koszem, ale i na obwodzie.

   - Przykłady z wykresu: Joel Embid, Nikola Jokic, Brook Lopez, Nikola Vucevic

2. Lewa Dolna Część: Jest to grupa zawodników reprezentujących bardziej tradycyjny styl gry na tej pozycji (skupienie na graniu w obrębie kosza - ujemne wartości PC2), którzy wciąż świetnie odnajdują swoje miejsce w lidze. Wciąż są kluczowymi zawodnikami (niska wartość PC1).

   - Przykłady z wykresu: Ivica Zubac, Rudy Gobert, Alperen Sengun

3. Prawa Górna Cześć: Są to zawodnicy rezerwowi, którzy wchodzą na boisko w bardzo konkretnym celu: aby oddać rzut z dystansu (mały wolumen i wysoka wartość PC2). Nie grają dużej liczby minut i rzadziej angażują się w walkę fizyczną pod koszem, ale dobrze rzucają za 3 punkty na tle reszty zawodników.

   Przykłady z wykresu: Mo Bamba, Karl-Anthony Towns, Willy Hernangomez

4. Prawa Dolna Część: Znajdują się tu gracze o najmniejszym wpływie na losy meczu. Nie posiadają rzutu z dystansu, a krótki czas gry nie pozwala im na wykręcenie wysokich statystyk w ataku czy obronie.

   - Przykłady z wykresu: Cody Zeller, James Wiseman, JaVale McGee

4 Skalowanie wielowymiarowe - MDS

4.1 Wprowadzenie

MDS służy do przedstawienia relacji między obiektami - w tym przypadku między zawodnikami NBA na pozycji centra - w postaci konfiguracji punktów w przestrzeni o określonych wymiarach. Celem jest przedstawienie dystansu między obiektami na wykresie, tak aby odległość między punktami jak najlepiej oddawały ich podobieństwo do siebie.

W analizie wykorzystano jako metodę skalowania - Klasyczną metodę skalowania oraz Metodę skalowania Sammona. Minimalizuje ona błąd odwzorowania oryginalych odległości i szczególnie akcentuje zachowanie małych dystansów. Algorytm oblicza konfigurację puntków, w której różnica między oryginalną a odwzorowaną macierzą odległości jest jak najmniejsza. Różnicę tą mierzy się za pomocą współczynnika STRESS. Im niższy tym wierniej odtworzono pierwotne odległości. W projekcie STRESS będzie interpretowany na podstawie tabelki: (Źródło: “Walesiak M, Gantar E, Statystyczna analiza danych z wykorzystaniem programu R, Wydawnictwo PWN, Warszawa, 2009.”)

Tabela 8: *Interpretacja współczynnika STRESS*

STRESS	Dopasowanie
>20%	bardzo słabe
10–20%	słabe
5–10%	średnie
2–5%	dobre
0–2%	bardzo dobre
0%	idealne

4.2 Standaryzacja i obliczenie dystansu między obiektami

Przed MDS dane zostały zestandaryzowane. Następnie obliczono oryginalne odległości pomiędzy obiektami. Będą one porównywane po skalowaniach.

4.3 Wyniki dla jedengo wymiaru

Tabela 9: *Współrzędne Sammon mapping dla pierwszych 6 zawodników*

Zawodnik	WspSammon
Joel Embiid	-6,5077
Nikola Jokic	-7,1229
Bam Adebayo	-4,8497
Kristaps Porzingis	-3,5899
Nikola Vucevic	-5,4950
Brook Lopez	-6,6898

Tabela 10: *Oryginalna macierz odległości (pierwszych 6 zawodników)*

	Joel.Embiid	Nikola.Jokic	Bam.Adebayo	Kristaps.Porzingis	Nikola.Vucevic	Brook.Lopez
Joel.Embiid	0,000	2,625	3,245	3,226	4,059	3,248
Nikola.Jokic	2,625	0,000	4,025	4,682	4,792	4,308
Bam.Adebayo	3,245	4,025	0,000	2,291	2,088	4,235
Kristaps.Porzingis	3,226	4,682	2,291	0,000	2,582	4,052
Nikola.Vucevic	4,059	4,792	2,088	2,582	0,000	5,063
Brook.Lopez	3,248	4,308	4,235	4,052	5,063	0,000

Tabela 11: *Macierz odległości po Sammon mapping (pierwszych 6 zawodników)*

	Joel.Embiid	Nikola.Jokic	Bam.Adebayo	Kristaps.Porzingis	Nikola.Vucevic	Brook.Lopez
Joel.Embiid	0,000	0,615	1,658	2,918	1,013	0,182
Nikola.Jokic	0,615	0,000	2,273	3,533	1,628	0,433
Bam.Adebayo	1,658	2,273	0,000	1,260	0,645	1,840
Kristaps.Porzingis	2,918	3,533	1,260	0,000	1,905	3,100
Nikola.Vucevic	1,013	1,628	0,645	1,905	0,000	1,195
Brook.Lopez	0,182	0,433	1,840	3,100	1,195	0,000

Tabela 12: *Współczynnik STRESS dla Sammon k = 1*

STRESS
0,1253

4.3.1 Wnioski - jeden wymiar

Przedstawione trzy tabele stanowią podglądowy wycinek pełnej analizy dla wszystkich zawodników. Zaprezentowano jedynie pierwsze 6 środkowych (z 78 analizowanych), by zobrazować sposób działania Sammon mapping i interpretacji wyników.

Współrzędne Sammon mapping (Tabela 7):

- Wartości Sammon pokazują “pozycję” zawodnika w przestrzeni jednowymiarowej
- Zawodnicy o podobnych współrzędnych są do siebie statystycznie zbliżeni - np. Joel Embiid i Brook Lopez.
- Duże różnice współrzędnych (np. między Jokiciem a Porzingisem) wskazują na wyraźnie odmienny profil gry.

Oryginalna macierz odległości (Tabela 8):

- Prezentuje rzeczywiste dystanse pomiędzy zawodnikami, bazując na wybranych statystykach.
- Małe wartości (np. między Embiidem a Jokiciem) oznaczają wysokie podobieństwo; duże wartości – odmienność stylu.

Macierz odległości po Sammon mapping (Tabela 9):

- Pokazuje, na ile udało się zachować względne odległości po rzutowaniu do jednej osi (k=1).
- Jeśli wartości są zbliżone do oryginału – model odwzorowuje relacje pomiędzy zawodnikami poprawnie.
- Różnice odległości mogą wskazywać na “utratę” informacji podczas redukcji wymiarowości (im mniej wymiarów – tym trudniej zachować pełnię relacji z oryginału - i tak właśnie jest w tym przypadku). Na podstawie tylko tej próbki można zauważyć, że wartości między tabelami odbiegają o siebie.

Współczynnik STRESS (Tabela 10):

- Dla k=1 STRESS wynosi 0,1253 (~12,5%), co według skali oznacza “słabe” dopasowanie.
- Taki wynik jest typowy przy rzutowaniu bardzo złożonych i wielowymiarowych danych do jednej osi – nie sposób oddać wszystkie relacje w 1D.
- Dlatego warto przejść do analizy dla większej ilości wymiarów - 2 i 3.

4.4 Wyniki dla dwóch wymiarów

Tabela 13: *Współrzędne Sammon mapping (k=2) dla pierwszych 6 zawodników*

Zawodnik	Sammon1	Sammon2
Joel Embiid	-4,8464	-3,4939
Nikola Jokic	-4,4810	-4,4228
Bam Adebayo	-4,2738	-0,9597
Kristaps Porzingis	-3,1172	-2,1593
Nikola Vucevic	-4,8222	-1,5879
Brook Lopez	-5,9082	-1,8706

Tabela 14: *Oryginalna macierz odległości (pierwszych 6 zawodników)*

	Joel.Embiid	Nikola.Jokic	Bam.Adebayo	Kristaps.Porzingis	Nikola.Vucevic	Brook.Lopez
Joel.Embiid	0,000	2,625	3,245	3,226	4,059	3,248
Nikola.Jokic	2,625	0,000	4,025	4,682	4,792	4,308
Bam.Adebayo	3,245	4,025	0,000	2,291	2,088	4,235
Kristaps.Porzingis	3,226	4,682	2,291	0,000	2,582	4,052
Nikola.Vucevic	4,059	4,792	2,088	2,582	0,000	5,063
Brook.Lopez	3,248	4,308	4,235	4,052	5,063	0,000

Tabela 15: *Macierz odległości po Sammon mapping k=2 (pierwszych 6 zawodników)*

	Joel.Embiid	Nikola.Jokic	Bam.Adebayo	Kristaps.Porzingis	Nikola.Vucevic	Brook.Lopez
Joel.Embiid	0,000	0,998	2,598	2,184	1,906	1,940
Nikola.Jokic	0,998	0,000	3,469	2,643	2,855	2,924
Bam.Adebayo	2,598	3,469	0,000	1,666	0,834	1,871
Kristaps.Porzingis	2,184	2,643	1,666	0,000	1,798	2,806
Nikola.Vucevic	1,906	2,855	0,834	1,798	0,000	1,122
Brook.Lopez	1,940	2,924	1,871	2,806	1,122	0,000

Tabela 16: *Współczynnik STRESS dla Sammon k = 2*

STRESS
0,0366

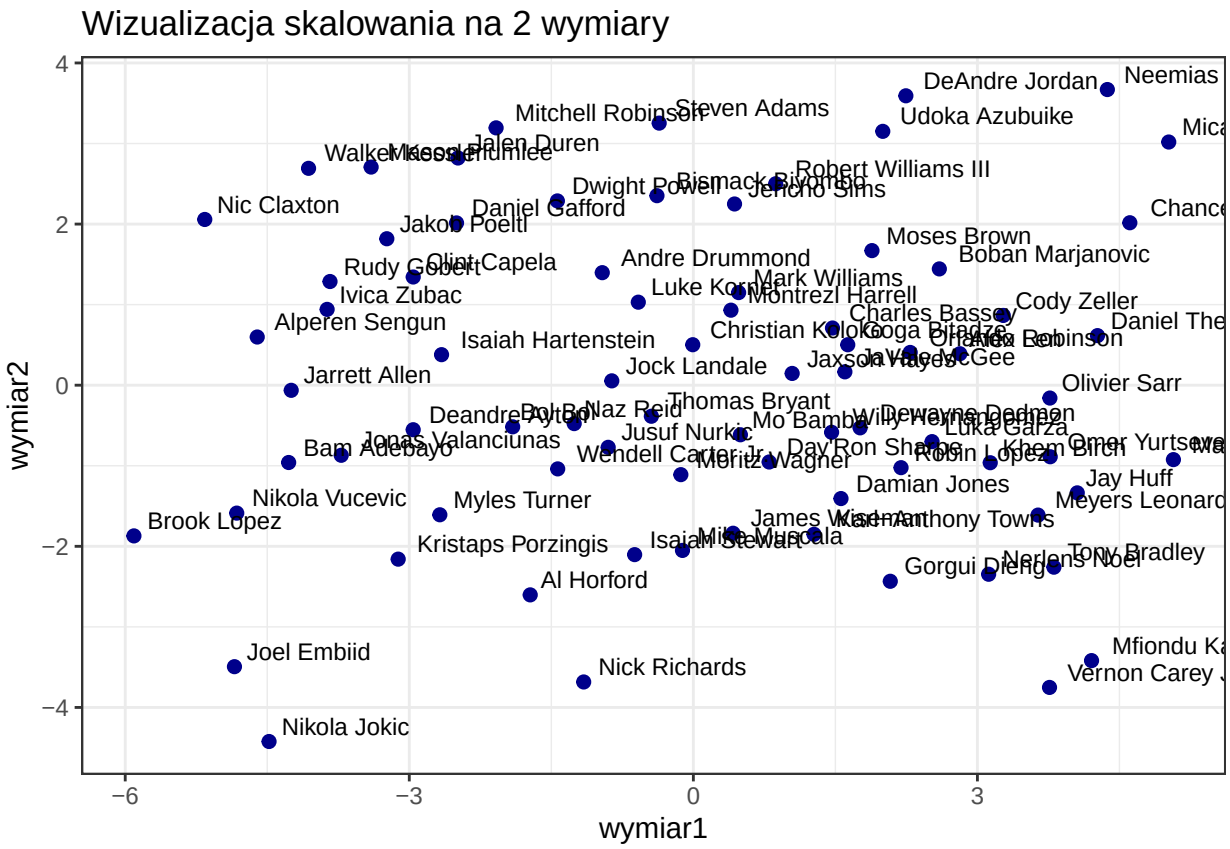

4.4.1 Wnioski - dwa wymiary

Współrzędne Sammon mapping (Tabela 11):

- Zawodnicy otrzymują dwie współrzędne (Sammon1, Sammon2), które odwzorowują ich profil statystyczny w dwuwymiarowej przestrzeni.
- Podobne współrzędne oznaczają zbliżony styl, efektywność, cechy gry – gracze “są blisko siebie” w sensie statystycznym. Np.: Joel Embiid i Nikola Jokic położeni są daleko od pozostałych – sugeruje to wyraźnie odmienny profil względem innych środkowych (być może wybitność w wybranych statystykach).

Oryginalna macierz odległości (Tabela 12):

- Ta sama tabelka co przy jednym wymiarze.

Macierz odległości po Sammon mapping (Tabela 13):

- Pozwala porównać, jak dobrze zachowano relacje oryginalne po redukcji do dwóch wymiarów.
- Można zauważyć wzrost podobieństwa wartości między dwoma tabelkami. Wciąż jednak różnica jest zauważalna.

Współczynnik STRESS (Tabela 14):

- STRESS dla k=2 jest bardzo niski (0,0366 ≈ 3,7%), co wg skali oznacza “dobre” dopasowanie.
- Potwierdza nam to, że rozszerzenie skalowania do dwóch wymiarów znacznie poprawiło dopasowanie.

Wykres 2D i grupowanie:

- Na wykresie zostali zwizualizowani wszyscy zawodnicy poddani analizie. Skorzystano ze współrzędnych, które zwróciła funkcja sammon() - Tabela nr 11.
- Wizualizacja pozwala zidentyfikować klastry i obserwacje odstające (np. graczy unikalnych/statystycznie wybitnych). Gracze o zbliżonych współrzędnych tworzą grupy – wspólny styl gry, podobny wpływ na statystyki zespołu. Obiekty oddalone od centrum lub innych graczy mogą reprezentować nietypowe profile zawodników.
- Przykładowo: Embiid, Jokic, Lopez, Richards wyraźnie wyróżniają się od reszty. Jeżeli spojrzymy w dane, znajdziemy tam potwierdzenie tej obserwacji. Joel Embiid był w tamtym sezonie MVP oraz liderem w ilości zdobytych punktów. Nikola Jokic zakończył sezon z najlepszym wskaźnikiem +/- co pokazuje jak bardzo jego obecność na boisku pomaga w zwycięstwach drużyny. Brook Lopez był liderem w ilości bloków. Ciekawym przypadkiem jest Nick Richards, który na wykresie mocno odstaje od reszty. Ze statystyk wynika, że jest on solidnym jednak tylko lekko ponadprzeciętnym graczem. Wyróżnia go jedynie 100% skuteczność rzutów za 3, jednak przy tylko 3 próbach, co nie czyni go lepszym.

Dlatego też zostanie przeprowadzona analiza dla 3 wymiarów aby sprawdzić czy możemy jeszcze polepszyć dopasowanie.

4.5 Wyniki dla trzech wymiarów

Tabela 17: *Współrzędne Sammon mapping (k=3) pierwszych 6 zawodników*

Zawodnik	Sammon1	Sammon2	Sammon3
Joel Embiid	-4,4243	-3,6558	1,2037
Nikola Jokic	-3,9365	-3,7132	3,0077
Bam Adebayo	-4,1329	-1,2695	0,1979
Kristaps Porzingis	-2,9233	-2,2961	-0,7436
Nikola Vucevic	-4,5769	-1,6294	-1,5016
Brook Lopez	-4,5830	-1,6831	3,3188

Tabela 18: *Oryginalna macierz odległości (pierwszych 6 zawodników)*

	Joel.Embiid	Nikola.Jokic	Bam.Adebayo	Kristaps.Porzingis	Nikola.Vucevic	Brook.Lopez
Joel.Embiid	0,000	2,625	3,245	3,226	4,059	3,248
Nikola.Jokic	2,625	0,000	4,025	4,682	4,792	4,308
Bam.Adebayo	3,245	4,025	0,000	2,291	2,088	4,235
Kristaps.Porzingis	3,226	4,682	2,291	0,000	2,582	4,052
Nikola.Vucevic	4,059	4,792	2,088	2,582	0,000	5,063
Brook.Lopez	3,248	4,308	4,235	4,052	5,063	0,000

Tabela 19: *Macierz odległości po Sammon mapping k=3 (pierwszych 6 zawodników)*

	Joel.Embiid	Nikola.Jokic	Bam.Adebayo	Kristaps.Porzingis	Nikola.Vucevic	Brook.Lopez
Joel.Embiid	0,000	1,870	2,606	2,810	3,384	2,897
Nikola.Jokic	1,870	0,000	3,729	4,136	5,009	2,153
Bam.Adebayo	2,606	3,729	0,000	1,845	1,793	3,180
Kristaps.Porzingis	2,810	4,136	1,845	0,000	1,937	4,431
Nikola.Vucevic	3,384	5,009	1,793	1,937	0,000	4,821
Brook.Lopez	2,897	2,153	3,180	4,431	4,821	0,000

Tabela 20: *Współczynnik STRESS dla Sammon k = 3*

STRESS
0,0114

4.5.1 Wnioski - trzy wymiary

Współrzędne Sammon mapping (Tabela 15):

- Każdy zawodnik otrzymuje trzy współrzędne — Sammon1, Sammon2, Sammon3 — które reprezentują jego statystyczny profil w przestrzeni trójwymiarowej.
- Podobieństwo współrzędnych oznacza zbliżony styl i efektywność gry, natomiast duże różnice na jednej lub kilku osiach mogą wskazywać na unikalne cechy zawodnika.

Oryginalna macierz odległości (Tabela 16):

- Pokazuje pierwotne statystyczne dystanse pomiędzy zawodnikami.

Macierz odległości po Sammon mapping k=3 (Tabela 17):

- Pokazuje, jak układ zawodników w nowej przestrzeni 3D odwzorowuje ich realne relacje.
- Zauważalna jest jezcze wyższa zgodność rozkładu odległości względem macierzy oryginalnej niż było to w przypadku dwóch wymiarów.

Współczynnik STRESS (Tabela 18):

- STRESS dla k=3 wynosi 0,0114 (~1,1%), co według skali klasyfikuje się jako “bardzo dobre dopasowanie”.
- Oznacza to, że rzutowanie do 3 wymiarów niemal idealnie odzwierciedla oryginalne relacje między zawodnikami — model trójwymiarowy zawiera prawie całą informację z danych wejściowych.

Wykres 3D i grupowanie:

- Widoczne jest duże skupienie zawodników w centrum figury. To zawodnicy, którzy mają zbliżone parametry gry i nie wyróżniają się na tle innych.
- Warto spojrzeć na obiekty odstające, które są o wiele lepiej widoczne na wykresie. Joel Embiid i Nikola Jokic znajdują się bardzo blisko siebie i wyraźnie poza głównym skupiskiem. Wynik ten znajduje swoje potwierdzenie. W tamtym sezonie Joel Embiid został wybrany na MVP sezonu, a Nikola Jokic był drugi w tym zestawieniu.
- Ivica Zubac, Clint Capela oraz Rudy Gobert tworzą wyraźnie jedno skupisko. Patrząc na statystyki (tabelka poniżej) widzimy wielkie podobieństwo. Wszyscy są głównymi centrami w swoich drużynach, doświadczonymi i wszechstronnymi zawodnikami.

PName	GP	W	L	Min	PTS	FG.	X3P.	FT.	OREB	DREB	BLK	X...
Rudy Gobert	70	34	36	2148,5	939	65,9	0	64,4	231	583	95	-7
Ivica Zubac	76	43	33	2169,4	818	63,4	0	69,7	236	520	98	-33
Clint Capela	65	35	30	1730,1	779	65,3	0	60,3	258	459	79	-30

- Vernon Carey Jr. oraz Mfiondu Kabengele tworzą małe skupisko w prawej górnej części wykresu. Oboje mają prawie identyczne statystyki - 6 pkt. zdobytych w całym sezonie, mniej niż 10 bloków i minusowe +/-. To grupa najgorzej radzących sobie zawodników w lidze na pozycji centra.

PName	GP	W	L	Min	PTS	FG.	X3P.	FT.	OREB	DREB	BLK	X...
Mfiondu Kabengele	4	3	1	36,4	6	28,6	0	100	5	5	0	-5
Vernon Carey Jr.	11	8	3	28,5	6	25,0	0	100	3	8	2	-10

- Ciekawym zjawiskiem jest oddalenie od wszystkich innych DeAndre'a Jordana. Dla fanów koszykówki to postać znana, jednak nieelitarna. Intuicja podpowiada, że powinien on być gdzieś w środku bryły. Po spojrzeniu na dane widzimy, że ma on bardzo podobne statystyki co Jericho Sims oraz Udoka Azubuike. To trójka, która zakończyła sezon z najlepszą skutecznością rzutową. Jedyną różnicą jest 100% skuteczności Jordana przy rzutach za 3, podczas gdy pozostali mają 0%. To wielka statystyczna różnica, jednak po zgłębieniu danych okazuje się, że wszyscy oddali jeden rzut w sezonie, jednak tylko Jordan zamienił go na 3 punkty. To pokazuje jak ważny jest dobór zmiennych oraz interpretacja wyników analizy przy wykorzystaniu danych wejściowych.

PName	GP	W	L	Min	PTS	FG.	X3P.	FT.	OREB	DREB	BLK	X...
DeAndre Jordan	39	23	16	585,9	199	76,5	100	45,8	52	150	23	-119
Jericho Sims	52	31	21	812,4	178	77,6	0	75,0	99	143	28	-113
Udoka Azubuike	36	17	19	358,5	125	81,9	0	35,0	31	88	15	-83

5 Podsumowanie

Przeprowadzona analiza statystyczna z wykorzystaniem technik redukcji wymiarowości (PCA) oraz skalowania wielowymiarowego (MDS) pozwoliła na kompleksową ocenę profilu zawodników występujących na pozycji środkowego (Center) w lidze NBA w sezonie zasadniczym 2022/2023. Obie metody, choć odmienne, doprowadziły do spójnych i uzupełniających się wniosków.

Analiza Głównych Składowych (PCA) okazała się kluczowa dla zrozumienia struktury danych. Pozwoliła zredukować zbiór 12 zmiennych do trzech interpretowalnych wymiarów: ogólnej jakości zawodnika (PC1), stylu gry (PC2 – podział na graczy obwodowych i podkoszowych) oraz wpływu na zwycięstwa (PC3). Dzięki temu zidentyfikowani zostali gracze ogólnie lepsi od przeciętnych oraz ich styl z podziałem na tradycyjną dominację fizyczną lub nowoczesną gry na dystansie.

Metoda skalowania wielowymiarowego (MDS), a konkretnie algorytm Sammona, świetnie dopełniła ten obraz, wizualizując podobieństwa między konkretnymi graczami. W przeciwieństwie do PCA, gdzie analizujemy cechy, MDS pozwoliło zobaczyć relacje między każdym z zawodników w przestrzeni. Technika ta skutecznie wyodrębniła klastry graczy o zbliżonym profilu oraz zidentyfikowała przypadki nietypowe, elitarne. Szczególnie cenna była analiza w trzech wymiarach, gdzie współczynnik STRESS spadł do poziomu 1,1%, co oznacza niemal idealne odwzorowanie rzeczywistych różnic między zawodnikami.

Finalnie, analiza potwierdziła silną polaryzację ligi. Zarówno PCA, jak i MDS wyraźnie oddzieliły wąską elitę supergwiazd (jak Embiid czy Jokic) od szerokiego grona zadaniowców, pokazując, że w dzisiejszej NBA o wartości środkowego decyduje nie tylko wzrost i siła, ale coraz częściej wszechstronność i unikalny zestaw umiejętności.